

面向覆盖率的规划器引导记忆残差强化学习方法： 机器人热斑覆盖研究

蒋健, 毛轶海 *

中国科学院沈阳计算技术研究所, 沈阳, 中国

中国科学院大学, 北京, 中国

449192322@qq.com, myhfree@126.com

摘要—颗粒热处理容器内的局部蒸汽突破点在线出现, 并持续存在直至被机械臂覆盖。本文在 ABB 机械臂的 MuJoCo 数字孪生环境中研究该持续服务问题: 外部热定位模块提供聚集分布的目标位置, 机械臂驱动覆盖中心服务活动热斑。Horizon-2 滚动时域规划器提供结构化动作先验, LSTM-PPO 策略依据活动目标集合、生成历史、热场上下文和路线摘要学习带阶段缩放及进度保护的有界残差。实验采用 3 个训练种子、3 个留出环境种子, 并在每个交叉单元运行 5 个回合。相较 Horizon-2, 本方法在 Low、Realistic 和 Hard 阶段的覆盖率无统计可区分差异; Extreme 阶段由 0.816 提高至 0.855, 差值的分层 95% 置信区间为 [0.003, 0.074], 但经四阶段 Holm 校正后不显著。保留编码器、H2 行为克隆预热、预测损失和服务奖励的匹配绝对动作消融, 使四阶段覆盖率降低 0.079-0.168。Extreme 阶段的覆盖率增加同时伴随更高延迟与积压。因此, 本方法体现的是以覆盖率为主的规划-学习权衡, 而非统一更快的控制器。

关键词—机器人覆盖, 残差强化学习, 持续服务, 覆盖路径规划, LSTM-PPO, MuJoCo

I. 引言

本文面向颗粒床上甑与蒸制过程中的机械臂辅助作业。外部热感知系统检测局部蒸汽突破点, ABB 机械臂移动铺料或覆盖中心, 依次服务活动位置。仿真器直接提供目标坐标, 因此本文评价在线控制和服务路径决策, 不讨论相机感知。目标以空间聚集的爆发-沉寂周期到达, 在被覆盖前持续存在, 并可能在机械臂移动过程中积累。该任务因而属于持续服务问题, 需要联合考虑几何行程、等待时间、目标年龄和队列拥塞。

该问题与覆盖路径规划 [1]、覆盖控制 [2]、统计覆盖 [3]、随机到达下的持续监测 [4] 以及随机动态车辆路径问题 [5], [6] 相关。与静态区域覆盖不同, 活动热斑仅在物理覆盖后离开队列。已有研究将强化学习用于自适应覆盖 [7], [8]; 然而, 在目标位置可见时, 确定性规划器本身已构成有竞争力的先验。残差强化学习 [9] 及有界残差控制 [10], [11] 能够在保留该先验的同时学习局部修正, 集合编码器则遵循 Set Transformer 的置换不变思想 [12]。

本文主要对应 ICCV Track 6 (Robotics), 并与 Track 2 (AI for Engineering) 和 Track 4 (Machine Learning) 相关。研究问题为: RQ1, 相较匹配的绝对动作 PPO 控制器, 有界规划残差接口能否提高固定规划器的性能; RQ2, 该方法与其他规划器及启发式先验相比如

何; RQ3, 其在延迟、严格 SLA、积压和平滑度上形成何种覆盖率-服务代价权衡。

本文不以学习替代规划, 而是在在线路线先验周围学习修正。主要贡献包括: (1) 给出指标分母明确的持续热斑服务建模; (2) 构建具有阶段化残差权限和进度保护的 LSTM-PPO 接口; (3) 采用交叉留出评估, 将残差动作接口的证据与辅助模块作用区分开来。

II. 任务与方法

A. 持续服务与评价指标

设活动热斑集合为 $\mathcal{S}_t = \{p_i(t)\}$, 其中 $p_i = (x_i, y_i, a_i)$ 表示位置与活动年龄, 覆盖中心为 $c_t = (x_t, y_t)$ 。当

$$\|c_t - (x_i, y_i)\|_2 \leq r_{\text{cover}} \quad (1)$$

时, 热斑 i 完成服务并被移除。报告实验禁用超时移除, 因此未覆盖热斑仍计入分母。动作 $u_t = [\Delta x_t, \Delta y_t, s_t] \in [-1, 1]^3$ 每 0.05 s 下发一次, MuJoCo 物理积分步长为 0.002 s。覆盖率定义为

$$C = N_{\text{covered}} / N_{\text{spawned}}. \quad (2)$$

对已覆盖热斑, 响应时间为 $T_i = (n_i^{\text{cover}} - n_i^{\text{spawn}}) \times 0.05$ s, 平均延迟为 $\bar{T} = N_{\text{covered}}^{-1} \sum_i T_i$ 。平均值和 p90 均以已覆盖热斑为条件, p90 为单回合延迟列表的经验 90 百分位数。严格 SLA 定义为

$$C_{\text{SLA}} = \frac{|\{i : T_i \leq T_{\text{SLA}}\}|}{N_{\text{spawned}}}, \quad T_{\text{SLA}} = 4.0 \text{ s}. \quad (3)$$

积压为时间平均活动热斑数; 平滑度为 $\Delta_u = T^{-1} \sum_t \|u_t - u_{t-1}\|_2$ 。统计重采样前先在评估单元内聚合, 覆盖率为主要指标。

B. 规划先验与循环残差

风险感知比较器使用

$$q_i = 0.40\phi_{\text{age}} + 0.30\phi_{\text{dist}} + 0.10\phi_{\text{reach}} + 0.20\phi_{\text{therm}}. \quad (4)$$

各分量为

$$\begin{aligned} \phi_{\text{age}} &= \text{clip}(a_i / A_{\text{norm}}, 0, 1), \\ \phi_{\text{dist}} &= 1 - \text{clip}(\|p_i - c_t\| / R_{\text{pot}}, 0, 1), \\ \phi_{\text{reach}} &= 1 - \text{clip}(\|p_i - p_{\text{home}}\| / R_{\text{max}}, 0, 1), \\ \phi_{\text{therm}} &= \text{clip}(H(p_i), 0, 1). \end{aligned} \quad (5)$$

* 通信作者: 毛轶海。




Fig. 1. 规划器引导的残差控制框架。在线规划器始终位于动作回路内；LSTM-PPO 给出有界修正，进度保护器在动作发送至 MuJoCo 机械臂前检查局部进展。

TABLE I
Horizon-2 目标选择流程

- 输入：活动集合 S_t 、覆盖中心 c_t 和 $L = 2$ 。
1. 枚举 $\mathcal{R}_t = \text{Perm}(S_t, \min(2, |S_t|))$ 并计算各路线 $J(\rho)$ 。
 2. 令 $\rho^* = \arg \max J(\rho)$ ；严格大于比较使并列时保持枚举顺序。
 3. 输出指向 p_{ρ^*} 的归一化方向及速度 1，并裁剪至 $[-1, 1]^3$ 。
 4. 下一决策步重新规划，不传递规划器隐状态。

材料缺口分量为 $\phi_{\text{mat}} = \text{clip}(\text{mean}_g[\max(H^* - H_g, 0) \exp(-\|x_g - p_i\|^2 / (2\sigma_d^2)) / H^*, 0, 1)$ ，其中 $\sigma_d = 0.18 \text{ m}$ 。热场分量为 $H(p) = \text{clip}(\sum_{\ell} a_{\ell} \exp(-\|p - h_{\ell}\|^2 / (2\sigma_h^2)), 0, 1)$ ， $\sigma_h = 0.22 \text{ m}$ 。启用材料观测时，年龄、距离、材料、可达性和热场权重为 $(.35, .25, .15, .10, .15)$ ；V12 关闭材料观测及可选紧迫度增强，故实际权重为 $(.40, .30, 0, .10, .20)$ 。风险感知启发式无隐状态，选择活动集合中首个取得最大 q_i 的热斑，并以速度 1 输出指向该目标的归一化方向。

Horizon- L 枚举长度为 $\min(L, N_t)$ 的有序路线。对 $\rho = (i_1, \dots, i_L)$ ，规划器模拟行程并计算

$$g_j = q_{i_j} + 0.45z_j - 0.018d_j - 0.050(z_j - 1)_+,$$

$$J(\rho) = \sum_{j=1}^L 0.82^{j-1} g_j - 0.08 \bar{z}_{\text{left}}, \quad (6)$$

其中 d_j 为行程步数， z_j 为以 A_{norm} 归一化的预计到达年龄；每个路线元素后更新模拟中心和累计行程。H2 取 $L = 2$ ，H3 取 $L = 3$ 。规划器枚举全部有序路线，使用 $d_j = \max(1, \lceil \max(\|p_{i_j} - c\| - r_{\text{cover}}, 0) / 0.04 \rceil)$ ，完全并列时保留首个枚举路线，并仅执行最高分路线的首个动作。环境随后应用 $\bar{u}_t = 0.7\bar{u}_{t-1} + 0.3\tilde{u}_t$ ；平面位移为 $0.04\eta_t[d_x, d_y]$ ，其中 $\eta_t = 0.65 + 0.35(d_s + 1)/2$ 。

观测由 $61 + 8 \times 8 = 125$ 维特征组成。全局分支为 $61 \rightarrow 256$ ；8 个热斑槽经共享的 $8 \rightarrow 128$ 映射和 4 头掩码注意力编码，再由 $128 \rightarrow 256$ 映射；拼接特征通过 $512 \rightarrow 256 \rightarrow 256$ 融合层进入单层、宽度 256 的 LSTM。共享循环表征连接 $256 \rightarrow 3$ 策略头、 $256 \rightarrow 1$ 价值头及 $256 \rightarrow 128 \rightarrow 2$ 预测头。策略均值使用 $\tanh$ ，状态无关




Fig. 2. MuJoCo ABB 工作空间（左）与在线热斑服务任务（右）。控制器在圆形热斑内移动绿色覆盖中心。

的对数标准差初始化为 -0.8 。相对坐标和距离按热斑半径缩放，年龄按 A_{norm} 缩放；关节量和末端跟踪误差保留仿真单位，不使用测试集运行归一化器。隐状态跨采样分块和覆盖事件传递，在遗漏事件和回合边界重置。

给定规划动作 u_t^{base} 和残差 $u_t^{\text{res}} = \pi_{\theta}(o_t, h_t)$ ，候选动作

$$\tilde{u}_t = \text{clip}(u_t^{\text{base}} + \beta_t k_t u_t^{\text{res}}, -1, 1),$$

$$\beta_t = 0.03 + 0.17 \text{clip}(n_t / 700000, 0, 1). \quad (7)$$

沉寂、稀疏、积累、中等、密集和爆发阶段的 k_t 分别为 $(1.35, 1.25, 1.00, 1.00, 0.40, 0.25)$ 。保护器拒绝方向一致性低于 0.15 的动作，要求候选进展至少达到基准进展的 0.35 且容差为 0.002；保护混合为 0.70 基准加 0.30 候选，并保留至少 0.50 基准进展。转向余弦低于 -0.55 时进行混合，连续 90 步未覆盖后拒绝比基准更差的候选。该机制是局部进度过滤器，不构成形式化时序逻辑安全保证 [13]。

标量奖励包含时间、活动数、平均年龄、势函数、最佳进展、覆盖、快速覆盖、精度、延迟、最老目标、积压、SLA、动作变化、动作范数、遗漏和成功项。四阶段覆盖、快速覆盖和势函数基础值分别为 $(68, 64, 62, 60)$ 、 $(16, 14, 12, 10)$ 和 $(8.0, 7.5, 6.5, 5.8)$ ；对应缩放系数为 $(.70, 3.0, .65, .65, .45, 2.4, 2.8)$ 。其余系数为 $r_{\text{time}} = (.030, .035, .045, .055)$ 、 $r_{\text{latency}} = 30$ 、 $r_{\text{oldest}} = .45$ 、 $r_{\text{backlog}} = .20$ 、 $r_{\text{SLA}} = (20, -30)$ 、 $r_{\Delta u} = .025$ 、 $r_{\|u\|} = .004$ 、 $r_{\text{miss}} = 28$ 和 $r_{\text{success}} = 30$ 。由于关闭超时移除，遗漏项不激活。总奖励乘 0.02 并裁剪至 $[-4, 4]$ ；SLA 和积压因此属于标量偏好而非硬约束。

TABLE II
阶段与训练参数

阶段	$N_{\max}$	r_{cover}	A_{norm}	p_{spawn}	冷却步数
Low	3	.17	260	.006	80
Realistic	4	.14	220	.010	65
Hard	6	.12	200	.018	48
Extreme	8	.10	180	.026	36

观测/宽度 125; 热斑 128, 全局/LSTM 256; 4 头注意力
序列/更新 $4 \times 800 = 3200$; 每 4 个分块更新 PPO

TABLE III
本方法与 Horizon-2 的覆盖率比较 (分层 95% 置信区间)

阶段	本方法	H2	Δ	Δ 区间	p_{Holm}
Low	.917 [.906,.929]	.919 [.906,.932]	-.002	[-.018,.016]	1.000
Real.	.901 [.884,.922]	.896 [.883,.910]	+.005	[-.018,.034]	1.000
Hard	.870 [.844,.894]	.870 [.847,.894]	< .001	[-.040,.033]	1.000
Extreme	.855 [.828,.881]	.816 [.782,.849]	+.038	[.003,.074]	.135

III. 实验

A. 协议与统计单位

MuJoCo 数字孪生 [14] 包含 ABB 机械臂、圆形甬锅和外部目标场。3 个漂移热区依次经历 70 步沉寂、110 步积累, 随后每 4 步逐个生成 3-5 个热斑; 背景权重和强度为 0.055 和 3.8。每种学习方法采用训练种子 0-2、留出环境种子 100-102, 每个交叉单元运行 5 个 3200 决策步回合, 并使用固定课程后的终点检查点。每个种子的训练预算为 $1152 \times 800 = 921600$ 决策步。

PPO 采用 $(\gamma, \lambda) = (.985, .95)$ 、Adam 学习率及 ϵ 均为 10^{-5} 、1 个优化轮次、策略/价值裁剪 (.05, .05)、价值系数 .5、梯度范数 .35, 熵系数在 10^6 步内由 8×10^{-4} 降至 1.8×10^{-4} 。课程阶段回合数为 80/160/720/192; H2 行为克隆使用 200 个回合 (20/40/100/40) 和 12 个训练轮次; 预测系数 .05、预测时域 150 步; BC 系数在 260000 步内由 .03 降至 0; 残差系数在 700000 步内由 .03 升至 .20。PPO 损失还包含 (.02, .002) 的动作平滑和动作 ℓ_2 项, 优势在每次更新内标准化, 总计 288 次 PPO 更新。每 50 个训练回合及阶段边界保存检查点, 报告模型为回合 1152 后的终点 latest_full 文件; 留出数据不参与模型选择。匹配变体使用固定 V12 配置、相同预算和动作接口, 未完成统一超参数搜索; 历史 Vanilla 未进行独立的全预算调优。

评估窗口固定为 3200 决策步, 即 160 s。协议关闭超时移除和终端排空, 因此窗口结束时仍活动的热斑继续计入覆盖率分母和积压。每个回合先计算各指标, p90 不跨回合池化; 单元内先平均 5 次重复, 再对训练种子、环境种子和回合分别进行 20000 次交叉分层自助重采样。配对方法复用相同场景, 确定性规划器省略训练种子层, 并在各预先定义的四阶段比较族内进行 Holm 校正。

B. 覆盖率与基线

表 III 给出主要比较。前三阶段中本方法与 H2 无统计可区分差异; Extreme 差值的未校正区间为正, 但经四阶段 Holm 校正后不显著。风险感知方法在 Extreme 的点估计更高, H3 和规划器集成在部分阶段具有相近点估计。风险感知方法的非单调结果 (.924, .901, .836, .863) 来自容量、覆盖半径、到达率和 A_{norm} 的联合变化, 而非隐状态。




Fig. 3. 带分层 95% 置信区间的阶段覆盖率。差异主要出现在 Extreme 阶段, 且经多重比较校正后不再显著。

TABLE IV
确定性与学习基线的覆盖率。方括号内为分层 95% 置信区间, $\pm$ 为评估种子标准差。

方法	Low	Real.	Hard	Extreme
本方法	.917 [.906,.929]	.901 [.884,.922]	.870 [.844,.894]	.855 [.828,.881]
Horizon-2	.919 [.906,.932]	.896 [.883,.910]	.870 [.847,.894]	.816 [.782,.849]
Horizon-3	.917 $\pm$.009	.927 $\pm$.025	.860 $\pm$.022	.841 $\pm$.060
风险感知	.924 [.902,.953]	.901 [.885,.918]	.836 [.778,.876]	.863 [.833,.892]
最近优先	.922 $\pm$.011	.887 $\pm$.016	.860 $\pm$.026	.789 $\pm$.050
最老优先	.914 $\pm$.004	.890 $\pm$.014	.883 $\pm$.019	.807 $\pm$.032
距离-年龄	.921 $\pm$.016	.896 $\pm$.008	.851 $\pm$.020	.801 $\pm$.065
动态加权	.927 $\pm$.003	.886 $\pm$.023	.865 $\pm$.005	.799 $\pm$.045
ACO-TSP	.925 $\pm$.006	.893 $\pm$.004	.864 $\pm$.033	.754 $\pm$.061
规划器集成	.935 $\pm$.012	.899 $\pm$.014	.870 $\pm$.003	.814 $\pm$.090
无残差	.838 [.712,.915]	.776 [.667,.865]	.726 [.590,.837]	.687 [.585,.793]
Vanilla LSTM-PPO	.166 [.067,.286]	.130 [.048,.234]	.089 [.025,.181]	.061 [.017,.115]

确定性方法采用相同环境种子和动作接口。Vanilla 因训练协议存在混杂, 仅作为带区间的描述性诊断, 不作为因果基线。

C. 动作接口、服务代价与鲁棒性

匹配的无残差策略保留观测、LSTM、H2 预热、预测损失、服务奖励和训练预算, 但输出绝对动作, 且不含规划基准或保护器。该比较用于检验完整规划-残差动作接口。历史 Vanilla 同时改变残差组合、BC 与预测, 且未完成全预算独立调优, 因此不作因果解释。

在 Extreme 阶段, 相较 H2, 0.038 的覆盖率增加伴随平均延迟增加 2.50 s、p90 增加 6.09 s、平均活动热斑数增加 0.26 及严格 SLA 降低。在未见的更高密度条件下, 本方法在 Hard/Extreme 获得 .868/.850, H2 获得 .888/.825; 区间重叠, 因此仅作为鲁棒性证据。H3 结果只检验确定性规划器容量, 不代表匹配 H3 残差的迁移能力。

TABLE V
机制与服务证据: (a) 匹配残差接口效应; (b) 组件核算; (c) 相对 H2 的覆盖率-服务诊断。

(a) 匹配残差接口效应							
阶段	完整方法	无残差	Δ	Δ 区间	p_{Holm}		
Low	.917	.838 [.712, .915]	+ .079 [.004, .202]		.029		
Real.	.901	.776 [.667, .865]	+ .124 [.036, .223]		.003		
Hard	.870	.726 [.590, .837]	+ .144 [.037, .268]		.011		
Extreme	.855	.687 [.585, .793]	+ .168 [.050, .285]		.003		

(b) 组件核算							
变体	动作	BC	注意力	传递	预测	服务	保护
完整方法	H2+ 残差	是	是	是	是	是	是
无残差	绝对	是	是	是	是	是	否
无注意力	H2+ 残差	是	否	是	是	是	是
无传递	H2+ 残差	是	是	否	是	是	是
无预测	H2+ 残差	是	是	是	否	是	是
无服务奖励	H2+ 残差	是	是	是	是	否	是
Vanilla	绝对	否	是	是	否	是	否

(c) 相对 H2 的覆盖率与服务诊断							
阶段	方法	覆盖率	平均延迟 (s)	p90(s)	严格 SLA	积压	Δ_u
Low	本方法	.917	12.54	24.15	.181	2.30	.0254
	H2	.919	12.16	23.72	.191	2.28	.0255
Real.	本方法	.901	16.04	29.70	.147	2.84	.0261
	H2	.896	16.52	29.45	.131	2.82	.0258
Hard	本方法	.870	19.59	38.10	.127	3.49	.0277
	H2	.870	19.23	35.44	.121	3.43	.0274
Extreme	本方法	.855	23.88	46.01	.103	3.81	.0289
	H2	.816	21.38	39.92	.128	3.55	.0277

平均和 p90 延迟以已覆盖热斑为条件; 严格 SLA 以全部生成热斑为分母。积压为平均活动数, Δ_u 为每步平均动作变化。




Fig. 4. 留出 Realistic 场景的代表性轨迹。总体结论基于训练种子与评估种子的交叉单元。

IV. 讨论与结论

匹配动作接口比较表明, 完整规划-残差接口与覆盖率提升一致, 但该结果不能证明本方法优于 H2 或风险感知启发式。前三阶段中 H2 与学习方法无统计可区分差异, Extreme 差值在 Holm 校正前为正、校正后不显著。历史 Vanilla 同时改变残差组合、BC 和预测, 故仅作为描述性诊断; 现有辅助消融也不能证明注意力、隐状态传递、预测或服务塑形分别产生独立增益。

H3 检验的是确定性规划器容量, 而非残差迁移, 因为学习控制器以 H2 为基础训练。0.05 s 间隔表示任务时间而非模型推理时间, 固定窗口也不要求最终清空全部活动热斑。因此, 本文证据适用于固定时域持续服务; 终端排空评估、匹配 H3 残差训练和硬件时序验证仍需后续完成。

References

- [1] E. Galceran and M. Carreras, "A survey on coverage path planning for robotics," *Robotics and Autonomous Systems*, vol. 61, no. 12, pp. 1258-1276, 2013.
- [2] J. Cortes, S. Martinez, T. Karatas, and F. Bullo, "Coverage control for mobile sensing networks," *IEEE Transactions on Robotics and Automation*, vol. 20, no. 2, pp. 243-255, 2004.
- [3] O. Arslan, "Statistical coverage control of mobile sensor networks," *IEEE Transactions on Robotics*, vol. 35, no. 4, pp. 889-908, 2019.
- [4] J. Yu, S. Karaman, and D. Rus, "Persistent monitoring of events with stochastic arrivals at multiple stations," *IEEE Transactions on Robotics*, vol. 31, no. 3, pp. 521-535, 2015.
- [5] D. J. Bertsimas and G. van Ryzin, "A stochastic and dynamic vehicle routing problem in the euclidean plane," *Operations Research*, vol. 39, no. 4, pp. 601-615, 1991.
- [6] —, "Stochastic and dynamic vehicle routing in the euclidean plane with multiple capacitated vehicles," *Operations Research*, vol. 41, no. 1, pp. 60-76, 1993.
- [7] J. P. Carvalho and A. P. Aguiar, "Deep reinforcement learning for zero-shot coverage path planning with mobile robots," *IEEE/CAA Journal of Automatica Sinica*, vol. 12, pp. 1594-1609, 2025.
- [8] K. Champagnie, B. Chen, F. Arvin, and J. Hu, "Online multi-robot coverage path planning in dynamic environments through pheromone-based reinforcement learning," in *Proceedings of the IEEE International Conference on Automation Science and Engineering*, 2024, pp. 1000-1005.
- [9] T. Johannink, S. Bahl, A. Nair, J. Luo, A. Kumar, M. Loskyll, J. A. Ojea, E. Solowjow, and S. Levine, "Residual reinforcement learning for robot control," in *Proceedings of the IEEE International Conference on Robotics and Automation*, 2019, pp. 6023-6029.
- [10] Y. Yan, E. V. Mascaró, T. Egle, and D. Lee, "I-CTRL: Imitation to control humanoid robots through bounded residual reinforcement learning," *IEEE Robotics & Automation Magazine*, vol. 32, pp. 59-67, 2025.
- [11] T. Zhang, R. Wang, S. Wang, Y. Wang, G. Zheng, and M. Tan, "Residual reinforcement learning for motion control of a bionic exploration robot—robodact," *IEEE Transactions on Instrumentation and Measurement*, vol. 72, pp. 1-13, 2023.
- [12] J. Lee, Y. Lee, J. Kim, A. Kosiorsek, S. Choi, and Y. W. Teh, "Set transformer: A framework for attention-based permutation-invariant neural networks," in *Proceedings of the International Conference on Machine Learning*, 2019, pp. 3744-3753.
- [13] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, and U. Topcu, "Safe reinforcement learning via shielding," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.
- [14] E. Todorov, T. Erez, and Y. Tassa, "MuJoCo: A physics engine for model-based control," in *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2012, pp. 5026-5033.