

ICCC 2026 论文 IC069 大修审稿意见回复

中文对照版本

蒋健, 毛轶海

修订后题目: 面向覆盖率的规划器引导记忆残差强化学习方法: 机器人热斑覆盖研究

感谢审稿人提出细致的大修意见。我们认同原投稿稿件在控制器定义、交叉实验依赖关系处理以及历史 Vanilla LSTM-PPO 结果解释方面不够充分。修订后的英文稿严格保持 5 页 IEEE 会议格式, 同时压缩重复讨论, 以纳入必要的方法定义、统计分析、基线比较和研究限制。

1 修订概述

1. 引言明确将 ICCC Track 6 作为主要方向, 具体说明 ABB/MuJoCo 热处理场景、外部目标定位假设和三个可检验研究问题。
2. 相关工作增加随机动态路径、形式化保护、约束强化学习和近期残差控制文献。
3. 完整定义指标分母、风险感知评分、Horizon-2/Horizon-3 目标函数、网络维度、残差调度、动作保护、奖励系数、训练预算、课程学习和评估协议。
4. 主要不确定性分析改为 20000 次交叉分层自助重采样, 分别保持训练种子、评估环境种子和回合的依赖关系, 并在四阶段内进行 Holm 校正。
5. 历史 Vanilla LSTM-PPO 不再用于因果归因。主要机制证据来自匹配的绝对动作消融, 该消融保留观测、LSTM、H2 预热、预测目标、奖励、课程和训练预算。
6. 增加覆盖率、仅对已覆盖热斑计算的平均/p90 延迟、以全部生成热斑为分母的严格 SLA、活动积压和动作平滑度。
7. 收缩结论边界, 不再声称本方法统一优于 Horizon-2 或具有统一速度优势。

2 研究范围、ICCC 定位与研究问题

审稿意见: 明确论文在 ICCC 中的方向定位, 具体化物理过程, 并提出可检验的研究问题。

作者回复: 修订后的引言将 Track 6 (Robotics) 作为主要方向, 并说明与 Track 2 (AI for Engineering) 和 Track 4 (Machine Learning) 的联系。任务被具体描述为 ABB 机械臂在颗粒热处理容器上服务由外部热定位模块给出的蒸汽突破点。仿真研究评价在线控制与服务路径决策, 相机感知不属于本文范围。

引言提出三个研究问题:

- **RQ1:** 相较匹配的绝对动作 PPO 控制器, 有界规划残差接口能否提高固定规划器的性能?
- **RQ2:** 该方法与其他规划器及启发式先验相比如何?
- **RQ3:** 该方法在延迟、严格 SLA、积压和平滑度上形成何种覆盖率-服务代价权衡?

3 缺失文献与技术定位

审稿意见: 增加保护机制、约束强化学习和随机动态路径方面的工作。

作者回复: 修订稿引用 Alshiekh 等人的动作保护研究、Achiam 等人的约束策略优化以及 Bertsimas 和 van Ryzin 的随机动态路径研究, 并明确两个边界。第一, 本文的策略后进度检查是局部动作过滤器, 不提供形式化时序逻辑安全保证。第二, 延迟和积压通过标量奖励表达, 本文方法不是 CMDP/CPO 算法。

4 可复现性与论文表达

审稿意见：精确定义 Horizon-2 和风险感知方法，报告关键参数，增加组件矩阵，删除排版性元叙述，并修正带符号零值。

作者回复：修订后的方法部分和参数表新增以下内容：

- 材料观测关闭时，风险评分的年龄、接近度、可达性和热场权重为 0.40、0.30、0.10 和 0.20；启用材料观测时，年龄、接近度、材料、可达性和热场权重为 0.35、0.25、0.15、0.10 和 0.15。
- 给出材料缺口、目标层高度、沉积核宽度和高斯热场归一化方式，并明确 V12 关闭可选紧迫度增强。
- 给出 Horizon- L 有序路线枚举、模拟行程评分、折扣、剩余目标年龄项、并列处理和首动作执行规则。
- 报告 125 维观测、8 个目标槽、128 维目标嵌入、4 头注意力和 256 维 LSTM。
- 报告残差系数从 0.03 到 0.20 的 700000 步预热过程及六个阶段倍率。
- 报告方向一致性阈值、进度比例与容差、反向转弯阈值、停滞阈值和保护混合比例。
- 报告全部关键奖励系数、动作周期、SLA、阶段设置、PPO 参数、行为克隆、辅助预测、训练预算和留出评估协议。
- 报告固定 3200 决策步评估窗口、关闭超时移除和终端排空的设置，以及终点 latest_full 检查点选择规则。

组件矩阵明确列出 Full、No residual、No attention、No carry、No prediction、No service 和 Vanilla 的动作接口及组件状态。Hard 阶段差值由 -0.000 修正为 < 0.001 。

项目证据来自 V12 的 config.json、episodes.csv 和共享实现代码。episodes.csv 记录每个回合的奖励、覆盖率、SLA、残差比例、循环状态传递/重置计数、预测监督事件和累计训练步数，可用于核验课程完成及调度执行；留出评估不参与检查点选择。论文还区分了 MuJoCo 积分步长 0.002 s 与高层动作及指标周期 0.05 s，并分别说明成功奖励和因禁用超时而不激活的遗漏项。

5 规划器失配与时域敏感性

审稿意见：检验学习结果是否依赖 Horizon-2，并增加低成本的规划时域比较。

作者回复：修订稿加入使用相同路线目标函数、但令 $L = 3$ 的 Horizon-3 确定性基线。H3 在 Low 至 Extreme 阶段的覆盖率分别为 0.917、0.927、0.860 和 0.841；H2 分别为 0.919、0.896、0.870 和 0.816。这表明更长时域并非在所有阶段均更优，并提供了规划器容量比较。

同时，我们修正了解释边界。学习残差以 H2 动作作为基础，因此确定性 H3 结果不能证明残差可迁移到不同基础规划器。本次修订尚未完成匹配的 H3 残差重训练，正文未作时域无关性声明。

6 贡献归因

审稿意见：Vanilla LSTM-PPO、No residual 与 Full 之间的关系不清晰，无法判断性能差异来源。

作者回复：历史 Vanilla 同时移除了残差组合、H2 行为克隆和预测目标，因此不进入因果结论。修订稿采用 Full 与匹配 No-residual 控制器比较。后者保留相同观测、循环编码器、H2 行为克隆预热、辅助预测损失、服务奖励、课程、优化器设置和 921600 步预算，但输出绝对 PPO 动作，不使用在线规划基准和进度保护器。

Full 减 No-residual 的覆盖率效应如下：

阶段	差值	分层 95% 置信区间	Holm 校正 p 值
Low	+0.079	[0.004, 0.202]	0.029
Realistic	+0.124	[0.036, 0.223]	0.003
Hard	+0.144	[0.037, 0.268]	0.011
Extreme	+0.168	[0.050, 0.285]	0.003

因此，当前支持的机制结论限定为完整规划-残差动作接口相对匹配绝对动作控制器的差异。注意力、循环状态传递、预测和服务塑形的分阶段消融结果存在混合效应，本文不将其表述为四项分别得到证明的独立创新。

7 基线、公平性、统计依赖与指标

7.1 基线公平性

审稿意见：重新调优直接 PPO 基线，或显著弱化由该基线得出的结论。

作者回复：历史直接 LSTM-PPO 结果保留为带不确定性区间的描述性诊断，但不进入因果比较或主要结论。修订稿不再声称直接 PPO 或 LSTM 必然失效。匹配 No-residual 实验能够控制观测、预热、辅助目标、奖励、课程和训练预算。由于尚未完成 Vanilla 的独立全预算调优，该结果不用于因果比较，仅作描述性报告。

确定性比较集合扩展为 Horizon-2、Horizon-3、最近优先、最老优先、距离-年龄、风险感知、动态加权、ACO-TSP 和规划器集成。风险感知方法在 Extreme 达到 0.863，略高于本方法的 0.855，因此正文不再声称普遍优越性。

7.2 分层不确定性

审稿意见：保持训练种子、评估种子和重复回合之间的依赖关系，不应将全部回合视作独立样本。

作者回复：每种学习方法采用 3 个训练种子与 3 个留出环境种子的交叉设计，每个单元包含 5 个回合。修订分析执行 20000 次交叉分层自助重采样，分别在训练标签、环境标签和所选单元内部的回合层重采样。配对方法复用相同留出场景，确定性规划器省略训练种子轴。每个预先定义的比较族在四阶段内应用 Holm 校正。

本方法减 Horizon-2 的校正结果为：

阶段	本方法减 H2	分层 95% 置信区间	Holm 校正 p 值
Low	-0.002	[-0.018, 0.016]	1.000
Realistic	+0.005	[-0.018, 0.034]	1.000
Hard	< 0.001	[-0.040, 0.033]	1.000
Extreme	+0.038	[0.003, 0.074]	0.135

Extreme 的未校正区间为正，但四阶段 Holm 校正结果不显著。摘要、结果、讨论和结论均已统一采用该表述。

7.3 分母和服务诊断

审稿意见：定义延迟和 SLA 的分母，并报告服务与平滑度指标，而非只报告覆盖率。

作者回复：覆盖率定义为已覆盖数/生成总数，窗口结束时仍活动的热斑保留在分母中。平均延迟和 p90 仅以已覆盖热斑为条件；严格 SLA 为 4 s 内覆盖数/生成总数，未覆盖热斑计为失败。积压为时间平均活动热斑数，平滑度为相邻决策步动作的平均欧氏变化。评估采用固定 3200 决策步窗口，关闭超时移除和终端排空，因此结果属于固定时域持续服务，不代表完整过程最终清空保证。

Extreme 阶段中，本方法与 H2 的平均延迟分别为 23.88 s 和 21.38 s，p90 为 46.01 s 和 39.92 s，积压为 3.81 和 3.55，严格 SLA 为 0.103 和 0.128，动作变化为 0.0289 和 0.0277。因此，论文将其表述为覆盖率优先的服务代价权衡，而非延迟优势。

7.4 未见条件

审稿意见：增加原条件之外的针对性验证。

作者回复：修订稿增加无需重新训练的更高密度评估。本方法/H2 在 Hard 阶段为 0.868/0.888，在 Extreme 阶段为 0.850/0.825。由于分层区间重叠，该结果仅作为鲁棒性证据，不表述为性能优越性。

8 五页修订

审稿意见：应将篇幅用于可复现性和验证，而非重复解释。

作者回复：英文修订稿严格保持 5 页 IEEE 会议格式。我们压缩了 **Extreme** 阶段的重复讨论、一般性 PPO 背景和非必要排版性表述，将机制、组件和服务证据合并为一个双栏表，并仅保留一组代表性轨迹，由此纳入精确定义、校正后的不确定性、扩展基线、组件核算及服务诊断。

9 尚未完成的验证

本次修订明确保留一项尚未完成的实验：采用 H3 作为行为克隆教师和在线基础规划器的匹配 H3 残差控制器。当前 H3 结果仅评价确定性规划器容量，因此论文未声称残差具有规划时域无关性。此外，当前证据来自 MuJoCo 固定窗口实验，不构成真实机械臂部署或完整 sim-to-real 验证。